
MetaFormer 구조 기반 통제 환경에서의 비교와 정량적 평가 지표 제시를 통한 비전 모델의 귀납 편향 분석

- ▷ 학 생 이 름: 김 성 훈 (2025-19744, 공과대학 컴퓨터공학부)
 구 윤 우 (2025-13923, 공과대학 컴퓨터공학부)
 이 민 섭 (2025-17674, 공과대학 컴퓨터공학부)
- ▷ 지 도 교 수: 박 재 식
- ▷ 지도교수 소속: 공과대학 컴퓨터공학부
- ▷ 대학원 도우미: 이 다 은
- ▷ 도 우 미 소속: 공과대학 컴퓨터공학부

이 보고서는 학생자율교육 프로그램의 취지와 원칙에 따라,
학부생 김성훈, 구윤우, 이민섭이 주도적이고 자율적으로 설계하여 시행한
연구를 바탕으로 직접 작성한 결과물임을 확인합니다.



- 목 차 -

Abstract	3
1. Introduction	3
2. Related Work	5
2.1. Understanding Vision Transformer Performance	5
2.2. Decoupling Architectural Components via Token Mixing	5
3. Proposed Architecture	6
3.1. MetaFormer Architecture	6
3.2. Token Mixers	7
3.2.1. ViT	8
3.2.2. Local ViT	8
3.2.3. MLP mixer	8
3.2.4. Convformer	9
4. Empirical Analysis	9
4.1. Experimental Setup	9
4.2. Performance Analysis across Token Mixers	9
5. Why Do Some Token Mixers Perform Better?	10
5.1. Effective Receptive Distance (ERD)	11
5.1.1. Effective Receptive Field (ERF)	11
5.1.2. Derivation of ERD	12
5.1.3. Empirical Analysis of ERD	12
5.2. Centered Kernel Alignment (CKA)	13
5.2.1. Comparison Within Same Token Mixer	13
5.2.2. Comparison Between Different Token Mixers	14
5.3. Loss Landscape Hessian Spectrum	15
6. Discussion	16
7. Conclusion	18
References	18
Appendix	20
A. Detailed Experimental Setup	20
B. Auxiliary ERF Heatmap results	20
C. Auxiliary ERD Results	23
D. Layer-wise ERD	24

Abstract

Vision Transformer(ViT)는 다양한 컴퓨터 비전 과제에서 뛰어난 성능을 보이며 기존 합성곱 신경망을 대체하는 표준 구조로 자리 잡았다. 그러나 이러한 성능 향상의 원인이 무엇인지에 대해서는 아직 명확한 합의가 이루어지지 않았다. 특히 self-attention의 핵심 특성으로 알려진 long range dependency와 data specific weight는 기존 ViT에서 서로 결합되어 있어 각각의 기여를 독립적으로 분석하기 어렵다.

우리는 MetaFormer 구조를 기반으로 모델 구조를 통제된 실험 환경을 구축하고, token mixer만을 변경하여 두 특성이 모델에 미치는 영향을 공정하게 분석하였다. ViT, local ViT, MLP Mixer, Convformer의 네 종류의 token mixer로 실험을 수행하였으며, 단순 성능 비교를 넘어 모델의 내부 동작을 분석하기 위해 Centered Kernel Alignment(CKA), loss landscape Hessian spectrum 분석을 적용하고, 새로운 정량 지표인 Effective Receptive Distance(ERD)를 제안하였다. ERD는 모델이 실제 추론 과정에서 활용하는 공간적 정보의 범위를 측정함으로써 구조적으로 부여된 귀납 편향이 학습된 모델에 어떻게 반영되는지를 정량적으로 평가한다.

실험 결과, long-range dependency는 모델이 입력 정보를 통합하고 표현을 형성하는 방식에 지배적인 영향을 미치며, ERD와 CKA 분석에서도 서로 다른 추론 전략을 유도하는 핵심 요인으로 나타났다. 반면 data-specific weight는 표현 학습보다는 loss landscape의 형태를 개선하여 최적화를 보조하는 역할을 수행하였다. 이러한 결과는 ViT의 성능 우위가 self-attention의 적응적 가중치 부여 능력 자체보다 장거리 상호작용을 모델링할 수 있는 구조적 특성과 더욱 밀접하게 관련되어 있음을 시사한다.

1. Introduction

인공신경망은 컴퓨터 비전[1], 자연어 처리[2], 로봇틱스[3] 등 다양한 분야에서 기존 접근법보다 향상된 성능을 나타내며 이를 빠르게 대체해 나가고 있다. 특히 컴퓨터 비전 분야에서는 괄목할 만한 성과를 달성하며 지배적인 접근법으로 자리 잡았다. 컴퓨터 비전 분야에서는 인공신경망 중 합성곱 신경망(Convolutional Neural Network, CNN) 구조에 기반한 접근법[4]이 널리 사용되어왔다. 그러나, 최근에 Vision Transformer(ViT) 모델[5]이 등장하며, CNN 기반 구조가 점차 transformer 기반 구조로 대체되는 흐름이 나타나고 있다.

ViT가 다양한 컴퓨터 비전 벤치마크에서 기존 CNN 기반 모델을 능가하는 성능을 보임에 따라 ViT의 성능 향상을 위한 다양한 연구가 활발히 진행되었다.[6][7] 그러나, 이러한 성능 우위가 어디에서 비롯되는지에 대한 근본적인 이해는 아직 정립되지 않았다. 현재까지의 연구는 주로 경험적 성능 향상에 초점을 맞추고 있으며, 모델 구조의 특성과 성능 간의 인과 관계를 설명하는 체계적인 분석은 부족한 실정이다.

일반적으로 ViT의 높은 성능은 ViT의 attention 연산과 CNN의 convolution 연산의 특성 차이에서 기인한다고 여겨진다.[8] 구체적으로는 ViT의 성능 향상을 돕는 attention 연산 만의 특성으로 (1) 먼 거리의 token 사이의 관계를 한 단계에서 파악하는 long range dependency와 (2) 입력 데이터에 따라 가중치가 동적으로 조정되는 data specific weight이 제시되었다. 그러나 이러한 설명은 정량적으로 검증하기 어렵고, 특히 attention 연산의 효과와 네트워크 전반의 구조적 차이에 의한 효과가 서로 얽

혀 있어 각각의 기여도를 분리하여 독립적으로 평가하는 것이 어렵다. 이에 따라 attention이 실제로 성능 향상의 핵심 요인인지, 또한 attention 연산 중 어느 요인이 성능 향상에 주로 기여했는지에 대한 파악은 여전히 불명확하다.

본 연구에서는 기존 transformer 구조를 추상화한 MetaFormer 구조를 도입한다. MetaFormer는 transformer의 attention과 다층 퍼셉트론(Multi-Layer Perceptron, MLP)의 역할을 각각 token 간 상호작용을 다루는 token mixer와 channel 간 상호작용을 다루는 channel mixer로 일반화한다.[9] 이를 통해 모델 구조의 영향을 배제하고 연산의 특성만을 공정하게 비교할 수 있다. 구체적으로, 본 연구에서는 MetaFormer 구조를 고정한 상태에서 token mixer만을 변화시킨 모델들을 비교한다. 이를 통해 attention 연산의 각 특성이 모델 성능에 미치는 영향을 독립적으로 분석한다.

본 연구에서는 표준적인 attention을 사용하는 ViT, long range dependency가 제한된 local ViT^[10], data specific weight을 가지지 않는 MLP mixer^[11], 두 특성 모두가 결여된 Convformer의 네 token mixer를 이미지 분류 과제에 대하여 학습한다. 이를 통해 attention 연산의 각 특성이 모델에 미치는 영향을 비교한다. 또한 본 연구는 단순한 성능 비교를 넘어, 모델의 내부 동작을 더 깊이 이해하기 위한 지표와 분석을 도입한다. 먼저 Centered Kernel Alignment (CKA)^[12] 기법을 적용하여 모델 내부 representation의 계층별 유사도를 비교하여 서로 다른 token mixer가 문제를 해결하는 전략이 어떻게 달라지는지 분석한다. 또한 Effective Receptive Field (ERF)^[13]를 계산하여 각 모델이 실제로 활용하는 공간적 정보의 범위를 측정하고, 이를 기반으로 모델의 장거리 의존성을 정량화하는 새로운 지표인 Effective Receptive Distance (ERD)를 제안한다. 마지막으로 loss landscape Hessian spectrum 분석^[14]을 수행하여 각 token mixer의 수렴 특성을 비교한다. 더 나아가, 본 연구에서는 대규모 데이터셋으로 사전학습된 ViT 모델을 reference model로 함께 분석한다. 이를 통해 관찰된 결과를 실제 고성능 비전 모델의 동작 방식과 비교하여 각 inductive bias의 역할을 더 명확하게 해석한다.

이러한 분석을 통해 본 연구는 attention의 각 특성이 모델 성능에 미치는 영향을 동일한 조건에서 공정하게 비교하였다. 실험 결과는 long range dependency가 모델이 입력 정보를 통합하고 문제를 해결하는 방식에 지배적인 영향을 미치는 반면, data specific weight은 최적화 과정에서 loss landscape의 형태를 개선하는 보조적인 역할을 수행함을 시사한다. 구체적으로 본 연구의 기여는 다음과 같다.

1. MetaFormer 기반의 통제된 실험 환경을 구축한다. 이를 통해 기존 ViT와 CNN 비교에서 분리하기 어려웠던 여러 구조적 요인을 통제하고, long range dependency와 data specific weight의 기여를 보다 공정하게 평가한다.

2. Effective Receptive Distance(ERD)를 제안한다. ERD는 ERF를 기반으로 모델이 실제로 활용하는 공간적 정보의 범위를 정량화하는 지표로, 구조적으로 부여된 inductive bias가 학습된 모델의 정보 활용 방식에 얼마나 반영되는지를 측정할 수 있도록 한다. 또한 ERD는 모델 아키텍처와 데이터셋에 독립적으로 적용 가능하여 다양한 비전 모델 간 비교를 위한 일반적인 분석 도구로 활용될 수 있다.

3. ViT에서 long range dependency와 data specific weight의 역할을 규명한다. 학습된 모델의 성능 및 일련의 분석 결과를 종합적으로 해석하면 long range dependency는 모델이 정보를 통합하고 문제를 해결하는 방식에 지배적인 영향을 미치는 반면, data specific weight는 주로 최적화 과정에서 loss landscape를 안정화하는 보조적인 역할

을 수행한다.

2. Related Work

2.1. Understanding Vision Transformer Performance

기존 연구들은 주로 ViT의 성능이 높은 이유를 self-attention을 통한 long range dependency 능력에서 찾았다. CNN은 국소적인 receptive field에 기반한 강한 locality inductive bias를 가지는 반면, ViT는 전역적인 정보 상호작용을 직접적으로 수행할 수 있다는 점이 핵심적인 차별점으로 제시되어왔다.[15][16]

하지만 이러한 설명은 최근 연구들에 의해 도전받고 있다. 대표적으로 ‘How Do Vision Transformers Work?’는 attention의 receptive field를 국소적으로 제한하더라도 성능이 유지되거나 오히려 최적화 측면에서 더 안정적인 결과를 보일 수 있음을 실험적으로 확인하였다. 이는 long range dependency가 ViT 성능의 핵심 이유가 아닐 수 있음을 시사한다. 이들은 convolution 연산 등 다른 모델의 연산과 다른 attention 연산의 특성 중 연산 파라미터가 데이터 특이적으로 조정되는 data specific weight을 다른 이유로 제시한다. 이는 ViT가 강력한 성능을 보이는 시나리오가 대규모 데이터와 충분한 모델 용량이 확보될 경우라는 점에서도 타당성을 가진다.

이와 함께 ViT의 일반화 특성과 표현 방식에 대한 연구들도 진행되었다. ViT는 CNN과는 다른 접근법으로 컴퓨터비전 과제를 해결하며, 전역적이고 형태 중심적인 표현을 학습함이 알려져 있다.[17] 또한, 적절한 학습 전략이 ViT 모델 구조와 dataset에 의한 한계를 상당 부분 보완할 수 있음이 밝혀졌다.[18] 더 나아가 attention 구조 자체만이 아닌 아키텍처의 세부 설계 요소도 성능에 큰 영향을 미친다는 연구 결과도 있다.[19]

이러한 배경은 ViT의 성능을 구성 요소 단위로 분해하여 분석할 필요성을 제기한다. 단일 요인으로 ViT의 성능을 설명하는 것은 어려운 일이다. 본 연구에서는 이를 위해 MetaFormer 구조를 도입해 각 요소를 독립화하여 평가한다.

2.2. Decoupling Architectural Components via Token Mixing

ViT의 동작 원리를 분석하는 데 있어 가장 큰 어려움 중 하나는 아키텍처 구성 요소들이 서로 얽혀 있다는 점이다. 기존 ViT에서는 모델의 형태와 구조, attention 연산의 특징 등 다양한 요인 중 각각의 요소가 성능에 미치는 영향을 분리하여 분석하기 어렵다.

이러한 문제를 해결하기 위해 ‘MetaFormer is Actually What You Need for Vision’는 transformer 구조를 보다 추상화하는 방식을 제안한다. 이들은 ViT의 연산을 (1) token mixing (transformer block의 attention에 대응), (2) channel mixing (transformer block의 MLP에 대응)의 두 가지 연산으로 추상화할 수 있음을 보였다. 이에 따르면 token mixer의 구체적인 형태가 반드시 self-attention일 필요는 없다. Attention, MLP, convolution, pooling 등 서로 다른 연산을 token mixer로 사용해도 ViT의 구조를 유지할 수 있다.

이와 유사하게 다양한 연구들[20][21]에서는 attention을 완전히 제거하고 MLP만으로 토큰 간 상호작용을 수행하는 구조를 제안하였다. 이들은 더 작은 파라미터로 ViT와 유사한 성능을 달성하였다. 이는 attention 연산이 ViT 성능 향상에 핵심 원인이 아닐 수 있다는 의문을 제기한다. 그러나 MLP에 기반한 token mixer들은 ViT의 성능을 뛰어넘

지는 못하였다.

여전히 학습 전략, 모델 크기, 데이터 처리 방식, 모델 구조 등의 차이가 결과에 영향을 미친다. 따라서 token mixing 방식의 효과를 명확히 평가하기 위해서는 통제된 실험 환경에서의 비교가 필요하다. 본 연구에서는 이를 만족하도록 MetaFormer 구조에 기반한 실험 환경을 제안한다. 이를 통하여 모델 아키텍처를 완전히 일치시키고, token mixer만을 변경한 일련의 실험을 수행하고, 각 token mixer의 특성이 유발하는 inductive bias와 성능에 대한 기여를 분석한다.

3. Proposed Architecture

3.1. MetaFormer Architecture

MetaFormer는 transformer의 attention 연산을 token mixer라는 개념으로 추상화한 구조이다. 저자들은 해당 구조가 컴퓨터비전에서 transformer 계열 모델의 우수한 성능을 이끄는 핵심 요인이라고 주장한다. 그러나 선행 연구에서 비교된 모델들이 동일한 MetaFormer 구조를 지녔다고 보기에는 다소 불충분한 측면이 있다. 본 연구에서는 이를 보완하여 더욱 명확하고, 일관된 구조를 제시하도록 MetaFormer 구조를 재정의한다. 선행 연구와의 차이점은 크게 2가지이다. 첫째, token mixer 이후에 적용하는 MLP module을 channel mixer로 추상화하였다. 이는 해당 모듈이 채널 간 정보를 혼합하는 역할이라는 점을 명확히 드러내기 위함이다. 둘째, ViT와 동일하게 downsampling 구조를 채택하지 않았다. 이는 모델 구조 상의 변인을 최소화하여 token mixer의 종류에 따른 변화를 공정하게 비교하기 위함이다.




Fig 1. 본 연구에서 재정의한 MetaFormer 모델의 구조. MetaFormer block은 토큰별 정보를 혼합하는 token mixer와 채널별 정보를 혼합하는 channel mixer로 추상화되며, 각 mixer는 pre-norm과 residual 구조를 포함한다. 입력은 Input Embedding을 거쳐 여러 층으로 쌓인 MetaFormer block을 통과한 후 GAP 방식으로 분류 라벨을 예측한다. 위쪽은 선행 연구의 구조, 아래쪽은 본 연구에서 새롭게 제안한 구조이다.

Fig 1은 기존 선행 연구의 모델 구조와, 본 연구에서 새롭게 정의한 MetaFormer 모델의 구조를 시각화하여 비교한 그림이다. 입력 I 는 patch embedding과 같은

embedding layer을 거쳐 특징 벡터로 변환된다.

$$X = \text{InputEmb}(I) \dots\dots\dots (1)$$

Feature vector는 token mixer와 channel mixer가 순차적으로 적용되는 MetaFormer block을 통과하여 변환된다. 해당 block에서는 각 mixer를 통과하기 전 입력에 대해 normalization을 먼저 적용하는 pre-norm 구조와 잔차 연결을 사용하였다.

$$Y = \text{TokenMixer}(\text{Norm}(X)) + X \dots\dots\dots (2)$$

$$Z = \text{ChannelMixer}(\text{Norm}(Y)) + Y \dots\dots\dots (3)$$

이후 down-sampling 없이 특징 벡터의 차원을 유지한 채로, 동일한 MetaFormer block을 반복 적용한다. 최종적으로 출력된 특징 벡터에 Global Average Pooling(GAP)을 적용한 후 선형 분류기에 통과시켜 분류 라벨을 예측한다.

$$\hat{z} = \frac{1}{N} \sum_{i=1}^N Z_i \dots\dots\dots (4)$$

$$\hat{y} = \text{Classifier}(\hat{z}) \dots\dots\dots (5)$$

본 연구에서 수행한 실험에서는 ViT의 2-layer MLP를 channel mixer로 사용하였다. 구체적인 수식은 아래와 같다.

$$y = W_2 \text{GELU}(W_1 x + b_1) + b_2 \dots\dots\dots (6)$$

$W_1 \in \mathbb{R}^{kd \times d}$, $W_2 \in \mathbb{R}^{kd \times d}$ 이고, d 는 feature vector의 embedding dimension, k 는 expansion factor를 의미한다. k 는 기본 값으로 4를 사용하였다.

본 연구에서는 위에서 정의한 MetaFormer 구조를 기반으로 4개의 token mixer를 설계하여 token mixer의 특성이 모델의 성능에 미치는 영향을 분석한다. 다음 절에서는 각 token mixer의 구체적인 설계를 소개한다.

3.2. Token Mixers

본 연구에서는 MetaFormer 구조에 적용할 token mixer로 global attention, local attention, convolutional layer, mlp를 설계하고, 각 token mixer를 사용한 모델을 ViT, local ViT, Convformer, MLP mixer로 명명하였다. 4개의 모델은 CNN과 ViT의 주요 차이점으로 여겨지는 long range dependency와 data specific weight의 유무에 따라 분류할 수 있다. Long range dependency는 입력 시퀀스 내에서 멀리 떨어진 토큰 간의 관계를 파악할 수 있는 능력을 의미하며, data specific weight은 토큰 혼합에 사용되는 가중치가 입력 데이터에 따라 동적으로 결정되는 특성을 의미한다. 이 두 가지의 특성은 token mixer의 구조에 내재되는 일종의 inductive bias로, Table 1은 그 관계를 보여준다.

Model	Long Range Dependency	Data Specific Weight
ViT	O	O
Local ViT	X	O
MLP mixer	O	X
Convformer	X	X

Table 1. Long range dependency와 data specific weight 유무에 따른 token mixer의 분류

ViT와 MLP mixer는 토큰 혼합 시에 다른 모든 토큰을 참조하므로 long range dependency를 지니는 반면, local ViT와 Convformer는 receptive field가 제한되어 있

어 long range dependency를 지니지 않는다. 또한 ViT, local ViT는 토큰 혼합 과정에서 토큰 사이의 관계를 나타내는 attention score를 가중치로 사용하므로 가중치가 data specific 하지만, CNN과 MLP mixer는 학습된 고정된 가중치를 사용하므로 data specific한 가중치를 가지지 않는다. 아래 절들에서 각 token mixer의 구조를 더 구체적으로 설명한다.

3.2.1. ViT

ViT는 토큰 간의 전역적인 관계를 학습할 수 있는 self-attention layer를 token mixer로 사용한다. 이는 다음과 같이 표현된다.

$$\text{Attention}(Q, K, V) = \text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \dots\dots\dots (7)$$

이때 $Q, K, V \in \mathbb{R}^{N \times d_k}$ 는 각각 query, key, value이며, d_k 는 head dimension을 의미한다. 위 식에서, $\text{Softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)$ 는 토큰을 섞을 때 사용되는 가중치 행렬이며, Q, K 는 고정된 값이 아닌 데이터에 따라 달라지는 값이다. 따라서 ViT는 long range dependency와 data specific weight를 모두 갖는다.

3.2.2. Local ViT

Local ViT는 ViT의 token mixer에서 long range dependency를 제거한 local attention layer를 token mixer로 사용하였다. 구체적으로, attention map에 mask를 적용하여 각 패치가 이미지 내에서 인접한 토큰만 참고할 수 있도록 receptive field를 제한하였다. 이는 CNN의 kernel과도 유사한 구조를 지닌다.




Fig 2. Kernel size 3일 때 local attention의 receptive field 시각화, 주황색 셀은 현재 토큰을 나타내며, 회색 셀은 현재 토큰이 참조할 수 있는 인접한 토큰을 의미한다. 그 이외의 셀은 참조가 제한된다.

Token mixing에 사용하는 가중치가 데이터에 따라 달라지는 점은 ViT와 동일하므로, local ViT는 data specific weight만을 가진다.

3.2.3. MLP mixer

MLP mixer는 선형 변환과 활성화함수만으로 구성된 MLP를 token mixer로 사용한다. MLP를 token mixer로 사용한 선행 연구로는 2-layer 구조를 사용한 MLP mixer,

1-layer 구조와 affine 변환을 적용한 ResMLP, gating unit을 사용한 gMLP^[22] 등이 있다. 본 연구에서는 이 중 MLP만을 선형적으로 중첩한 MLP mixer 아키텍처를 채택하였다. 이는 부가적인 설계 요소의 변화를 최소화하여 MLP 기반 token mixer의 특성이 모델의 성능에 미치는 영향을 더욱 명확하게 파악하기 위함이다. 연구에서 사용한 token mixer는 channel mixer에서 사용한 식 (6)과 구조가 동일하다. 차이점으로는 expansion factor인 k 를 2로 설정하였다. MLP는 모든 토큰을 참고할 수 있으므로 long range dependency를 가지나, token mixing에 사용하는 가중치는 선형 변환 행렬의 가중치로 고정되어 있으므로 data specific weight은 가지지 않는다. MLP mixer는 다른 token mixer과 다르게 positional embedding을 적용하지 않았다.

3.2.4. Convformer

Convformer는 convolution 연산을 token mixer로 사용한 모델이다. Convolutional layer에서는 local attention layer와 유사하게 kernel size에 따라 receptive field를 제한한다. 또한, token mixer의 역할에 집중하기 위하여 grouped convolution을 사용하여 채널 간 혼합을 수행하지 않았다.

$$Y_{ij} = \sum_x \sum_y W_{xy} X_{xy} \dots\dots\dots (8)$$

$$\left(i - \frac{k-1}{2} \leq x \leq i + \frac{k-1}{2}, j - \frac{k-1}{2} \leq y \leq j + \frac{k-1}{2} \right)$$

W 는 합성곱에 사용되는 커널 가중치 행렬이며 k 는 커널의 window size이다. X_{xy}, Y_{ij} 는 각 위치 $(x, y), (i, j)$ 에 해당하는 패치의 feature vector를 의미한다. 또한, 일반적으로 convolution 연산은 down-sampling 구조와 함께 사용되지만, 본 연구에서는 MetaFormer 구조의 일관성을 유지하기 위해 feature vector의 차원을 고정하였다. Convformer는 token mixer에서 사용하는 가중치가 커널의 가중치로 고정되어 있어 data specific weight을 가지지 않으며, receptive field가 제한되므로 long range dependency 역시 가지지 않는다.

4. Empirical Analysis

4.1. Experimental Setup

학습 및 분석을 위한 dataset으로 CIFAR-100과 Tiny ImageNet^[23]을 사용하였다. CIFAR-100은 100개의 클래스로 구성된 이미지 분류 벤치마크로, 50,000장의 학습 데이터와 10,000장의 테스트 데이터로 이루어져 있으며 이미지 해상도는 32×32 이다. Tiny ImageNet은 200개의 클래스로 구성된 이미지 분류 벤치마크로, 각 클래스당 500장의 학습 이미지와 50장의 검증 이미지로 이루어져 있으며 이미지 해상도는 64×64 이다. 두 데이터셋 모두 224×224 로 해상도를 조정하여 사용하였다.

CIFAR-100과 Tiny ImageNet 모두 데이터셋 규모가 크지 않아 transformer 계열의 대형 모델에서 pre-train 없이 학습할 경우 성능이 크게 저하되는 문제가 일어난다. 이를 해결하기 위해 DeiT^[24]에서 사용한 증강 방식을 차용하였다. 또한, 과적합을 방지하기 위하여 L2 정규화, stochastic depth, label smoothing과 같은 강력한 regularization 기법들을 사용하였다. 구체적인 증강 방식 및 학습 설정은 Appendix A에 기록하였다.

4.2. Performance Analysis across Token Mixers

본 절에서는 token mixer의 종류에 따른 모델의 분류 성능을 비교한다. Token mixer를 항등함수로 설정한 baseline 모델(identity)를 포함하여 총 5개 모델의 validation accuracy를 Fig 3에 나타냈다.




Fig 3. 학습 Epoch에 따른 모델의 분류 성능. 왼: CIFAR-100 오른: Tiny ImageNet

Dataset	Model	# of Params	Validation Acc(%)	NLL Loss
CIFAR 100	Identity	3.77M	60.63 / 83.42	2.73
	ViT	5.54M	78.14 / 92.94	1.77
	Local ViT	5.54M	77.07 / 92.69	2.05
	MLP mixer	5.58M	74.76 / 91.23	1.44
	Convformer	3.79M	81.29 / 93.79	1.87
Tiny ImageNet	Identity	3.78M	45.78	1.48
	ViT	5.56M	64.02	0.98
	Local ViT	5.56M	62.59	1.11
	MLP mixer	5.60M	61.33	0.77
	Convformer	3.81M	66.15	1.06

Table 2. Token mixer에 따른 모델의 파라미터 수와 분류 성능 및 NLL loss. Validation Acc에서 '/'로 구분된 두 값은 각각 top-1 / top-5 accuracy를 의미한다.

Token mixer를 적용한 네 가지 모델의 top-1 accuracy을 비교한 결과, CIFAR-100과 Tiny ImageNet 모두에서 Convformer가 각각 81.29%, 66.15%의 최고 성능을 기록하였다. 반면 MLP-Mixer는 각각 74.76%, 61.33%로 가장 낮은 정확도를 보였다. MLP-Mixer는 두 데이터셋에서 가장 낮은 정확도를 기록하였음에도 불구하고 가장 작은 NLL loss를 보였다. 이는 MLP-Mixer가 상대적으로 작은 규모의 데이터셋에서 학습 데이터에 대한 과적합 문제에 취약함을 의미한다.

일반적으로 long range dependency를 활용하는 모델이 그렇지 않은 모델보다 accuracy가 낮았다. 이미지 분류에서는 인접한 패치 간의 상관관계가 중요한 경우가 많으므로, 탐색 범위를 제한하는 것이 성능 향상에 유리하게 작용할 수 있다. 이는 본 실험에서 사용한 데이터셋 규모가 상대적으로 작기 때문으로 해석할 수 있다. Long range dependency의 장점은 충분한 데이터로부터 학습할 때 효과적으로 발현된다. 이러한 결과는 제한된 데이터 환경에서는 강한 long range dependency를 제공하지 않는 구조적 inductive bias가 더 효과적임을 시사한다.

다음 장에서는 각 inductive bias가 모델의 표현 학습 및 일반화 특성에 어떠한 영향을 미치는지 보다 심층적으로 분석한다.

5. Why Do Some Token Mixers Perform Better?

본 연구에서는 token mixer의 동작 원리를 분석하기 위해서 ERD, CKA와 loss landscape Hessian spectrum을 적용한다. ERD는 각 token mixer가 가지는 구조적인 long range dependency가 실제 추론 과정에서 어떻게 발현되는지 정량적으로 확인한다. CKA는 동일 모델 내부 및 서로 다른 모델 사이의 layer별 representation의 유사도를 비교한다. Loss landscape Hessian spectrum은 모델이 최종적으로 수렴한 지점의 곡률이 long range dependency와 data specific weight에 따라 어떻게 달라지는지 분석한다.

5.1. Effective Receptive Distance (ERD)

본 연구에서는 long range dependency를 정량적으로 표현하기 위해서 Effective Receptive Distance(ERD)를 새롭게 제안한다. ERD는 특정 output patch가 각 위치의 input patch로부터 얼마나 큰 영향을 받는지 측정하는 Effective Receptive Field(ERF)에 기반하여 계산된다. 또한 구조적인 locality가 더 강하게 주입된 token mixer일수록 더 작은 ERD를 갖는지 실험하여 구조적으로 부여한 성질이 학습 후 ERD로도 동일 순서로 나타나는지 확인하고, 그 과정에서 data specific weight의 영향을 관찰한다.

5.1.1. Effective Receptive Field (ERF)

ERF^[13]는 마지막 block의 feature map의 특정 output patch가 각 input patch로부터 얼마나 큰 영향을 받는지 측정한다. 이를 위해 기준이 되는 output patch를 anchor patch라고 하고, anchor patch에 대해 픽셀 단위의 역전파를 계산하고 이를 각 input patch에 대해 합산하여 정규화한다. 이때 spatial information을 보존하기 위해 최종 GAP과 classification head는 제거하며, 각 input patch의 양의 기여만 집계하기 위해 gradient에 ReLU 함수를 적용한다.

$$\text{ERF}(Y_{ij}, X_{kl}) \propto \text{ReLU}\left(\frac{\partial \text{ReLU}(Y_{ij})}{\partial X_{kl}}\right) \dots\dots\dots (9)$$

식 9는 (i, j) 에 위치한 anchor patch Y_{ij} 에 대해서 (k, l) 에 위치한 input patch X_{kl} 가 얼마나 영향을 주었는지 계산한다. 이때 특정 anchor patch Y_{ij} 를 기준으로 모든 input patch X_{kl} 에 대한 합 $\sum_{k,l} \text{ERF}(Y_{ij}, X_{kl})$ 이 1이 되도록 정규화한다.




Fig 4. 왼쪽에서부터 ViT, local ViT, MLP mixer, Convformer의 ERF heatmap. 시각화를 위하여 0.05를 기준으로 color map을 clip 하였다.

Fig 4는 각 token mixer에 대해 14×14 개의 전체 patch 중 중앙에 위치한 $(7,7)$ 을 anchor patch로 설정하였을 때의 ERF를 시각화한 결과이다. 구조적인 locality가 주입된 Convformer와 local ViT는 $(7,7)$ 에서 멀어질수록 ERF 값이 비교적 빠르게 감소한다. 반면 구조적인 long range dependency가 주입된 ViT와 MLP mixer는 $(7,7)$ 에서 멀리 떨

어진 input patch에 대해서도 비교적 높은 가중치를 갖는다. 또한, data specific weight을 가지는 ViT와 local ViT는 data specific weight을 가지지 않는 MLP mixer와 Convformer에 비해서 anchor patch의 위치인 (7,7)에 위치한 input patch의 영향을 더 크게 받는다. 이러한 경향성은 중심 patch 이외에 다른 anchor patch들에 대해서도 확인되었다. 추가 실험 결과는 Appendix B에 기록하였다.

5.1.2. Derivation of ERD

특정 anchor patch Y_{ij} 에 대해, $\sum_{k,l} \text{ERF}(Y_{ij}, X_{kl}) = 1$ 이고 $\text{ERF}(Y_{ij}, X_{kl}) \geq 0$ 이므로 $X_{ij} \sim \text{ERF}(Y_{ij})$ 를 확률 분포로 생각할 수 있다. 따라서 식 10과 같이 특정 anchor patch Y_{ij} 에 대한 $\text{ERD}(Y_{ij}, X_{kl})$ 를 계산할 수 있다. 이는 anchor patch Y_{ij} 가 평균적으로 얼마나 멀리 떨어진 input patch로부터 영향을 받는지 의미한다.

$$\text{ERD}(Y_{ij}) = \mathbb{E}_{X \sim \text{ERF}(Y_{ij})} [\text{dist}(Y_{ij}, X)] = \sum_{k,l} \text{ERF}(Y_{ij}, X_{kl}) \text{dist}(Y_{ij}, X_{kl}) \dots\dots\dots (10)$$

각 이미지에 대한 ERD는 모든 anchor patch에 대한 $\text{ERD}(Y_{ij})$ 의 평균으로 정의한다. 이후 token mixer에 대한 ERD는 모든 이미지에 대한 ERD의 평균으로 계산한다. 이때 anchor patch는 총 $P \times P$ 개이므로, ERD는 L1 distance에 대하여 식 11과 같이 계산할 수 있다.

$$\text{ERD} = \frac{1}{P^2} \sum_{i,j,k,l} (|i-k| + |j-l|) \text{ERF}(Y_{ij}, X_{kl}) \dots\dots\dots (11)$$

5.1.3. Empirical Analysis of ERD




Fig 5. Token mixer에 따른 ERD 및 sum ERF per Distance.

Fig 5는 각 token mixer에 대한 ERD 및 정규화된 각 거리별 ERF 가중치 총합을 나타낸다. ERD는 local ViT(2.36), Convformer(3.89), pretrained ViT(6.68), ViT(7.36), MLP mixer(8.60) 순으로 증가하였다. 구조적인 long range dependency를 가지는

token mixer가 구조적인 long range dependency를 가지지 않는 token mixer에 비해서 3~6 patch를 더 멀리 관찰한다. 또한 data specific weight을 가질수록 ERD가 더 작아진다. 구조적인 locality를 가지는 local ViT, Convformer 중에서 data specific weight이 있는 local ViT가 ERD가 약 1.5 더 작고, 구조적인 long range dependency를 가지는 ViT, MLP mixer 중에서 data specific weight이 있는 ViT가 ERD가 약 1.2 더 작다. 또한 ImageNet에 대해서 pretrain된 ViT는 CIFAR-100만 사용하여 학습된 ViT에 비해서 약 0.7 더 작다.

또한 구조적인 long range dependency가 주어지지 않은 token mixer는 거리가 10 이상인 patch 쌍에 대한 ERF 값이 거의 0에 수렴한다는 점을 알 수 있다. 이에 반해 구조적인 long range dependency를 갖는 token mixer는 오른쪽 꼬리가 더욱 두껍게 유지되는 점을 확인할 수 있다. 한편 data specific weight을 가지는 local ViT, ViT, 그리고 pretrained ViT는 distance가 0인 patch 쌍, 즉 anchor patch와 위치가 동일한 input patch에 의해 받는 ERF가 약 0.12로 비슷하다. 이는 data specific weight을 가지지 않는 Convformer와 MLP mixer의 distance가 0인 patch 쌍에 대한 ERF인 약 0.04에 비해 3배 이상 큰 수치이며, data specific weight이 ERD를 낮추는 데 기여하는 요인 중 하나이다.

구조적인 long range dependency의 주입은 실제 추론 과정에서의 ERD 증가로 발견된다는 점을 확인하였다. 또한 구조적인 locality의 주입 여부가 같은 token mixer는 data specific weight이 있을수록 ERD가 감소한다는 점을 확인하였다. 이는 data specific weight이 있는 모델은 더 가까운 patch에 더 높은 가중치를 두기 때문이라고 분석한다. 이러한 경향성은 이미지 패치 개수를 다르게 하거나 데이터셋이 바뀌어도 동일하게 유지된다. 추가 실험 결과는 Appendix C에 기록하였다.

5.2. Centered Kernel Alignment (CKA)

CKA^[12]는 두 representation이 서로 얼마나 유사한지 정량적으로 측정하는 기법이다. 식 12와 같이 Gram matrix의 matrix norm의 정규화된 크기를 기반으로 계산된다. CKA는 서로 다른 차원을 가지는 representation 사이에도 적용할 수 있다는 장점 덕분에 서로 다른 token mixer 사이에도 적용할 수 있다.

$$CKA(X, Y) = \frac{(\|X^T Y\|_F)^2}{\|X^T X\|_F \|Y^T Y\|_F} \dots\dots\dots (12)$$

본 연구에서는 임의의 두 모델의 i, j 번째 MetaFormer block의 output X_i, Y_j 에 대하여 $CKA(X_i, Y_j)$ 값을 계산하였다. 모든 X_i, Y_j 쌍에 대해 이를 계산한 후 heatmap 형태로 시각화하였다. CKA를 통해서 각 token mixer별 추론 과정에서 layer별 유사도가 어떻게 변화하는지 분석한다.

5.2.1. Comparison Within Same Token Mixer

동일한 모델의 각 block이 끝난 layer에서의 feature map 사이의 CKA를 계산하였다. 해당 결과는 Fig 6에서 확인할 수 있다. CIFAR-100에서 훈련된 token mixer는 구조적인 long range dependency의 유무에 따라 CKA의 변화 양상에서 뚜렷한 차이를 드러냈다. 구조적인 locality가 주입된 Convformer, local ViT는 특정 구간별로 뚜렷한 정사각형 구조가 나타난다. 이는 CNN과 유사하게 초기 block에서는 low-level feature를 생성하고, 후기 block에서 이를 통합해 classification에 알맞은 fine grained feature를

찾는 multi-step으로 문제에 접근함을 시사한다. 반면 구조적인 long range dependency가 주입된 MLP mixer와 ViT는 더 넓은 범위의 layer 사이에서 비교적 완만하고 일관된 유사도 패턴을 나타내어 CNN과 같은 multi-step이 아니라 one-step 방




Fig 6. 동일한 token mixer의 layer간 CKA 분석 결과. (위) 왼쪽부터 ViT, local ViT. (아래) 왼쪽부터 MLP mixer, Convformer, pretrained ViT.

식으로 추론함을 확인할 수 있었다. 한편 pretrained ViT는 CIFAR-100에서만 훈련된 ViT와는 달리 multi-step CKA를 나타낸다. 4장에서 확인할 수 있듯 multi-step으로 추론하는 token mixer가 one-step으로 추론하는 2가지의 token mixer에 비해서 validation accuracy가 더 높았다.

5.2.2. Comparison Between Different Token Mixers




Fig 7. 서로 다른 token mixer의 layer간 CKA 분석 결과. (위) 왼쪽부터 (local ViT, ViT), (MLP Mixer, ViT), (Convformer, ViT). (아래) (MLP mixer, local ViT), (Convformer, local ViT), (Convformer, MLP Mixer).

각각 ViT, local ViT, MLP mixer, Convformer를 사용하는 모델들 사이의 CKA를 계산하여 Fig 7에 나타내었다. 그 결과, long range dependency의 유무가 일치하는 token mixer 쌍이 representation 수준에서도 상대적으로 높은 유사도를 보이는 경향을 확인할 수 있었다. 특히 Convformer와 local ViT 사이, 그리고 MLP mixer와 ViT 사이의 CKA는 다른 token mixer 쌍의 CKA에 비해서 block index가 큰 영역까지 비교적 큰 값을 가지며 상대적으로 높은 연관성이 관찰되었다. 이는 5.2.1절의 결과와 함께 long range dependency의 유무에 따라 token mixer별로 각 block을 활용하여 추론하는 방식이 다르다는 주장을 뒷받침한다.

5.3. Loss Landscape Hessian Spectrum

Loss landscape analysis는 parameter space에서 loss의 분포를 관찰하여 모델의 훈련 과정을 분석하는 방법이다. 이는 최종 loss만을 보는 대신, 학습 과정에서 모델이 어떤 영역으로 수렴하는지, 그리고 그 주변 곡률 구조가 어떠한지 함께 살펴본다는 점에서 의미가 있다. 컴퓨터 비전 분야에서는 이 방법이 주로 모델 구조나 학습 설정의 차이가 수렴 및 일반화 능력에 어떤 영향을 주는지 판단하는 용도로 활용되었다. 대표적으로 loss surface를 2차원 contour map 또는 3차원 surface plot으로 시각화하는 방법과 Hessian 행렬의 고유값을 이용해 곡률을 정량적으로 분석하는 방법이 널리 사용되었다. 본 연구에서는 Hessian 행렬을 통해 Loss landscape의 구조를 분석하는 방식^[25]을 채택하였다.

Hessian 행렬은 parameter에 대한 loss의 2차 미분으로, 그 고유값으로부터 loss landscape의 곡률 구조를 파악할 수 있다. 그러나 모델의 parameter 수가 매우 크기에, 본 연구에서는 Hessian 행렬을 직접 생성하지 않고, 임의의 벡터에 대해 Hessian-vector product만을 계산하는 방식을 사용하였다. 이렇게 얻은 Hessian-vector product에 Lanczos algorithm를 적용하면, 전체 행렬을 다루지 않고도 Hessian의 최대 및 최소 고유값을 효율적으로 추정할 수 있다. 구체적으로는 학습 데이터를 mini-batch 단위로 뽑아 loss를 계산한 후, 위의 방식을 적용하여 최대/최소 고유값을 계산하였다. 이를 50개의 batch에 대해 반복하여 고유값들의 분포를 히스토그램으로 시각화하였다.

본 연구는 warm-up 직후의 모델에 대해 분석을 수행한 ‘How Do Vision Transformers Work?’와는 달리, 수렴 지점에 도달한 모델에 대하여 Hessian 분석을 수행하였다. 초기 학습이 안정적으로 수행되었는지보다, 학습이 충분히 진행된 이후 loss가 얼마나 안정적으로 수렴했는지를 판단하기 위함이다. Loss landscape의 특정 지점에서 Hessian 행렬의 최대 고유값의 크기는 해당 지점이 얼마나 sharp한지를 반영하며, 음의 고유값의 절댓값 크기는 loss surface가 non-convex한 정도를 나타낸다. 따라서 최대 고유값의 크기가 작을수록 모델이 noise에 대해 강건함을 의미하며, 음의 고유값의 절댓값이 작을수록 수렴점에서 더 안정적임을 의미한다.

Fig 8은 각 token mixer에 대해 mini-batch 단위로 추정한 Hessian의 최소 및 최대 고유값 분포를 나타낸다. 먼저 MLP mixer는 최대 고유값과 최소 고유값 모두 절댓값이




Fig 8. 각 token mixer에 따른 Hessian spectrum 비교. 왼쪽은 최소 고유값, 오른쪽은 최대 고유값의 분포를 나타내며, CIFAR-100에서 mini-batch별로 계산한 고유값을 모아 density로 표현하였다.

크게 나타나, loss landscape가 뽀족함과 동시에 non-convexity 또한 강한 것을 확인할 수 있었다. 이는 해당 모델이 안정적인 수렴점에 도달하지 못하였음을 시사하며, 실제로 MLP mixer가 다른 token mixer에 비해 낮은 분류 성능을 보인 점과도 일관된다. 반면, pretrained ViT는 최대 고유값과 최소 고유값 모두 절댓값이 가장 작은 영역에 분포하였다. 이는 사전학습된 모델이 가장 평탄하면서도 음의 곡률이 약한, 즉 안정적인 수렴점에 도달하였음을 의미한다.

ViT, local ViT, 그리고 Convformer의 경우에는 data specific weight의 유무에 따라 최대 고유값과 최소 고유값이 서로 다른 경향을 보였다. 최대 고유값의 경우 ViT와 local ViT가 Convformer보다 더 작은 값에 분포하여, data specific weight를 지닌 token mixer가 상대적으로 더 평탄한 loss landscape를 형성함을 확인할 수 있었다. 반면 최소 고유값의 경우 Convformer가 ViT 및 local ViT보다 절댓값이 더 작게 나타나, data specific weight를 지닌 token mixer가 오히려 더 큰 음의 곡률을 가지는 것으로 나타났다. 이는 data specific weight이 loss surface를 flatten하는 동시에 음의 고유값의 크기를 증가시켜 non-convexity를 키운다는 점을 보여주며, ‘How Do Vision Transformers Work?’에서 제시된 flatness와 convexity 사이의 trade-off와 일치하는 결과이다. 따라서 두 지표를 종합하면, 본 연구의 결과는 기존 연구의 관찰과 대체로 부합한다고 결론지을 수 있다.

6. Discussion

본 연구는 MetaFormer 구조를 기반으로 한 통제 실험을 통해 long range dependency와 data specific weight이라는 두 가지 inductive bias가 token mixer의 동작에 어떤 방식으로 기여하는지를 분석하였다. 분석은 ERD, CKA, loss landscape Hessian spectrum이라는 세 축에서 이루어졌으며, 대규모 데이터로 사전학습된 ViT를 일종의 ground truth로 함께 비교함으로써 각 분석 결과의 의미를 해석하였다. 본 절에서는 이러한 결과를 long range dependency와 data specific weight의 관점에서 종합적으로 논의한다.

먼저 구조적으로 제시된 long range dependency(structural inductive bias)의 유무는 모델이 학습을 통해 얻는 learned inductive bias의 형태를 지배적으로 결정한다. 본 연구에서 제안한 ERD는 실제 학습된 모델이 얼마나 멀리 떨어진 토큰을 보는지, 즉

long range dependency에 대한 learned inductive bias를 정량적으로 보여준다. 측정 결과 각 token mixer의 ERD 값은 long range dependency를 지닌 모델이 그렇지 않은 모델보다 더 큰 값을 가졌다. (local ViT < Convformer < ViT < MLP mixer). 주목할 점은 이러한 순서가 모델의 성능 순서와는 직접적으로 대응하지 않는다는 것이다. 즉 ERD는 성능과 같은 결과 지표보다는, 모델의 구조 자체에 의해 결정된다. 이는 long range dependency에 있어, 모델의 structural inductive bias가 학습이 수행된 후의 learned inductive bias에 결정적인 영향을 미친다는 것을 의미한다. 이러한 경향성은 pretrained ViT에서도 동일하게 관찰되었는데, 충분히 학습된 모델 역시 ERD가 크게 나타났다는 사실은 구조적으로 부여된 long range dependency의 효과가 데이터나 학습 정도와 무관하게 유지됨을 뒷받침한다.

Long range dependency는 또한 모델이 주어진 문제를 푸는 방식 자체를 규정한다. CKA 분석 결과, long range dependency를 가지지 않는 모델(local ViT, Convformer)은 초기 block에서 국소적인 low level feature를 형성한 뒤 후기 block에서 이를 high level feature로 통합하는 multi-step 방식으로 문제를 해결하는 반면, long range dependency를 가지는 모델(ViT, MLP mixer)은 각 layer의 표현 방식이 명시적으로 구분되지 않는 one-step 방식을 보였다. 이는 멀리 떨어진 토큰을 초기 block부터 참조할 수 있는 모델은 국소적인 feature를 먼저 형성할 유인이 없기 때문으로 해석된다. 그리고 본 연구에서 사용한 CIFAR-100과 같은 소규모 데이터셋에서는 multi-step 방식이 one-step 방식보다 더 우수한 성능을 보였다.

다만, pretrained ViT는 long range dependency를 지닌 모델임에도, CKA 상으로는 multi-step 방식으로 문제를 해결하였다. 이는 long range dependency의 유무가 문제 해결 방식을 결정짓는 절대적인 제약이 아니라, 데이터가 불충분할 때 모델이 기본적으로 의존하게 되는 경향성임을 시사한다. 즉 소규모 데이터셋에서 학습된 ViT는 구조적으로 부여된 bias를 따라 one-step 방식을 보이지만, pretrained ViT처럼 충분한 학습이 이루어진 경우 long range dependency를 지님에도 해당 문제에 대한 최적의 해법(i.e. multi-step)을 스스로 찾아갈 수 있는 것이다.

한편 data specific weight은 long range dependency와는 달리, 모델의 동작을 결정하는 데에 있어 보조적인 역할만을 한다. Loss landscape Hessian spectrum 분석 결과, data specific weight을 가진 모델(ViT, local ViT)은 그렇지 않은 Convformer에 비해 Hessian의 최대 고유값이 더 작은 영역에 분포하여, 보다 평탄한 loss landscape를 형성하였다. 그러나 동시에 최소 고유값의 절댓값은 오히려 더 크게 나타나, non-convexity가 증가하는 경향을 보였다. 즉 data specific weight은 loss surface를 평탄하게 만드는 동시에 음의 곡률을 키우는, flatness와 convexity 사이의 trade-off를 유발하며, 이는 선행 연구에서 제시된 관찰을 본 연구의 통제 환경에서 그대로 재현한 것이다. 다만 이러한 loss landscape 구조의 변화가 성능의 향상이나 표현 방식의 변화로 직접 이어지는 않았다. 이는 성능이 수렴점 근방에서의 곡률 구조뿐 아니라 수렴점 자체의 위치나 모델의 capacity와 같은 여러 요인에 의해 복합적으로 결정되기 때문으로 해석할 수 있다.

종합하면, long range dependency는 모델이 학습하는 inductive bias의 형태와 문제 해결 방식을 지배적으로 결정하는 주요한 요인인 반면, data specific weight은 성능이나 표현 방식보다는 loss landscape의 곡률 구조에 영향을 미치는 보조적 요인으로 해

식된다. 다만 이러한 해석에는 본 연구에서 성능의 우열을 가린 기준이 소규모 데이터셋이었다는 한계가 존재한다. Multi-step 방식의 우위나 data specific weight의 보조적인 역할은 모두 데이터가 충분치 않은 환경에서 도출된 결론으로, 데이터 규모가 달라질 경우 각 요인의 기여 또한 달라질 여지가 있다. 따라서 추후 ImageNet과 같은 대규모 데이터셋으로 확장하여 현재의 분석과 동일한 결과가 나오는지 검증할 필요가 있다.

7. Conclusion

본 연구는 MetaFormer 구조를 재정의하여 token mixer 외의 구조적 변인을 통제할 실험 환경을 구축하고, long range dependency와 data specific weight의 유무에 따라 분류되는 네 가지 token mixer를 CIFAR-100과 Tiny ImageNet에서 비교하였다. 또한 long range dependency를 정량화하는 새로운 지표인 ERD를 제안하고, 이를 CKA 및 loss landscape Hessian spectrum 분석과 함께 적용하였으며, pretrained ViT를 reference model로 두어 통제 환경의 결과가 고성능 모델에서도 유효한지를 검증하였다. 그 결과, long range dependency는 모델이 학습하는 inductive bias의 형태와 문제 해결 방식(multi-step/one-step)을 지배적으로 결정하는 주요 요인인 반면, data specific weight는 loss landscape의 곡률 구조에 영향을 미치는 보조적 요인임을 확인하였다. 특히 본 연구가 제안한 ERD는 구조적으로 부여된 long range dependency가 학습 이후의 모델 동작에 그대로 반영됨을 정량적으로 보여주며, 모델 아키텍처와 데이터셋에 독립적으로 적용 가능하다는 점에서 다양한 비전 모델을 체계적으로 비교하기 위한 일반적인 분석 도구로 활용될 수 있다.

다만 본 연구는 자원의 제약으로 인해 상대적으로 소규모의 데이터셋에서만 실험을 수행하였으며, 이로 인한 과적합과 데이터 규모의 제약으로 성능 관련 결론이 특정 방향으로 치우쳤을 가능성이 존재한다. 따라서 향후에는 데이터셋의 규모와 품질을 달리하며 실험을 확장할 필요가 있다. 이를 통해 구조적으로 주입되는 inductive bias가 모델의 동작에 그대로 반영된다는 본 연구의 핵심 결론이 데이터와 무관하게 유지되는지를 검증하는 한편, 데이터의 규모와 품질에 따라 모델의 문제 해결 방식이나 각 inductive bias의 성능 기여가 어떻게 달라지는지를 함께 탐구하고자 한다.

References

- [1] Krizhevsky, Alex, Ilya Sutskever, and Geoffrey E. Hinton. "Imagenet classification with deep convolutional neural networks." Advances in neural information processing systems 25 (2012).
- [2] Vaswani, Ashish, et al. "Attention is all you need." Advances in neural information processing systems 30 (2017).
- [3] Levine, Sergey, et al. "End-to-end training of deep visuomotor policies." Journal of Machine Learning Research 17.39 (2016): 1-40.
- [4] He, Kaiming, et al. "Deep residual learning for image recognition." Proceedings of the IEEE conference on computer vision and pattern recognition. 2016.
- [5] Dosovitskiy, Alexey, et al. "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale." 9th International Conference on Learning Representations. 2021.
- [6] Zhai, Xiaohua, et al. "Scaling vision transformers." Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022.
- [7] Chen, Xiangning, Cho-Jui Hsieh, and Boqing Gong. "When Vision Transformers Outperform ResNets without Pre-training or Strong Data Augmentations." International Conference on Learning Representation. 2022.
- [8] Park, Namuk, and Songkuk Kim. "HOW DO VISION TRANSFORMERS WORK?." 10th International Conference on Learning Representations. 2022.
- [9] Yu, Weihao, et al. "MetaFormer is actually what you need for vision." Proceedings of the IEEE/CVF conference on computer vision and pattern recognition. 2022.

- [10] Yang, Baosong, et al. "Convolutional self-attention networks." Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies, Volume 1 (Long and Short Papers). 2019.
- [11] Tolstikhin, Ilya O., et al. "Mlp-mixer: An all-mlp architecture for vision." Advances in neural information processing systems 34 (2021): 24261–24272.
- [12] Kornblith, Simon, et al. "Similarity of neural network representations revisited." International conference on machine learning. PMLR, 2019.
- [13] Luo, Wenjie, et al. "Understanding the effective receptive field in deep convolutional neural networks." Advances in neural information processing systems 29 (2016).
- [14] Li, Hao, et al. "Visualizing the loss landscape of neural nets." Advances in neural information processing systems 31 (2018).
- [15] Naseer, Muhammad Muzammal, et al. "Intriguing properties of vision transformers." Advances in Neural Information Processing Systems 34 (2021): 23296–23308.
- [16] Raghu, Maithra, et al. "Do vision transformers see like convolutional neural networks?." Advances in neural information processing systems 34 (2021): 12116–12128.
- [17] Zhang, Chongzhi, et al. "Delving deep into the generalization of vision transformers under distribution shifts." Proceedings of the IEEE/CVF conference on Computer Vision and Pattern Recognition. 2022.
- [18] Steiner, Andreas Peter, et al. "How to train your ViT? Data, Augmentation, and Regularization in Vision Transformers." Transactions on Machine Learning Research.
- [19] Darcet, Timothée, et al. "Vision Transformers Need Registers." International Conference on Learning Representations (ICLR). 2024.
- [20] Touvron, Hugo, et al. "Resmlp: Feedforward networks for image classification with data-efficient training." IEEE transactions on pattern analysis and machine intelligence 45.4 (2022): 5314–5321.
- [21] Wang, Ziyu, et al. "Dynamixer: a vision mlp architecture with dynamic mixing." International conference on machine learning. PMLR, 2022.
- [22] Liu, Hanxiao, et al. "Pay attention to mlps." Advances in neural information processing systems 34 (2021): 9204–9215.
- [23] Le, Yann, and Xuan Yang. "Tiny ImageNet Visual Recognition Challenge." CS231N, Stanford University, 2015.
- [24] Touvron, Hugo, et al. "Training data-efficient image transformers & distillation through attention." International conference on machine learning. PMLR, 2021.
- [25] Park, Namuk, and Songkuk Kim. "Blurs Behave Like Ensembles: Spatial Smoothings to Improve Accuracy, Uncertainty, and Robustness." In Proceedings of the 39th International Conference on Machine Learning (ICML), pp. 17390–17419. 2022.

Appendix

A. Detailed Experimental Setup

MetaFormer 모델의 기본 설정은 다음과 같다. Embedding dimension은 192, depth는 12, patch size는 16×16 이며, normalization으로는 layer normalization을 사용하였다. 학습 설정은 다음과 같다. Optimizer로는 AdamW를 사용하였으며, learning rate는 6.67×10^{-4} , batch size는 512로 설정하였다. LR scheduler로는 cosine annealing을 채택하였으며, warmup epoch는 기본값으로 20을 설정하였다. 총 학습은 1000 epoch 동안 진행하였다. 모델별로 구체적인 하이퍼 파라미터의 값은 Table A1에 나타내었다.

Hyperparameter	ViT	Local ViT	MLP mixer	Convformer
Weight Decay	0.05	0.05	0.05	0.05
Warmup Epoch	20	20	10	20
Layer Scale	X	X	1.0×10^{-5}	X
Label Smoothing	0.1	0.1	X	0.1
Dropout	X	X	X	X
Stoch. Depth	0.1	0.1	0.03	0.1
Gradient Clip.	5	5	5	5
Window Size	—	3	—	3

Table A1. 모델 별 학습 설정 및 하이퍼 파라미터. Window size는 local ViT와 Convformer에서 각 토큰이 참조할 수 있는 인접 패치의 범위를 나타내는 하이퍼 파라미터이다. MLP mixer는 학습 불안정성으로 인해 별도의 하이퍼파라미터 탐색을 수행하여 최적값을 설정하였다.

데이터셋의 작은 크기로 인한 과적합 문제를 해결하기 위하여, 본 실험에서는 기본적인 증강 방식인 Random Crop, Random Horizontal Flip과 함께 DeiT에서 사용한 증강 방식인 Rand Augmentation, Mixup, CutMix, Repeated Augmentation을 사용하였다. 각 증강 방식의 구체적인 하이퍼파라미터는 Table A2에 나타내었다.

Augmentation	Hyperparameter
Random Crop	4
Random Horizontal Flip	—
Rand Augment	2 / 9
Mixup prob.	0.8
Cutmix prob.	1.0
Mixup/Cutmix switch prob.	0.5
Repeated Augmentation	3

Table A2. 학습에서 사용한 증강 방식과 사용한 하이퍼파라미터.

B. Auxiliary ERF Heatmap results

중앙 anchor patch 외의 다른 anchor patch에 대해서도 ERF heatmap을 생성하였다. Fig B1, Fig B2는 각각 CIFAR-100 dataset를 resize한 이후의 이미지 기준으로 (0,0), (9,3)에 위치한 anchor patch에 대한 ERF heatmap이다.




Fig B1. Resize 이후 CIFAR-100 dataset의 (0,0) Anchor ERF heatmap




Fig B2. Resize 이후 CIFAR-100 dataset의 (9,3) Anchor ERF heatmap

Tiny ImageNet에 대해서도 ERF map을 생성하였다. Fig B3, Fig B4, Fig B5은 Tiny ImageNet에서 (0,0)과 (9,3), (7,7)에 위치한 anchor patch에 대한 ERF heatmap 이다.




Fig B3. Tiny ImageNet dataset의 (0,0) Anchor ERF heatmap




Fig B4. Tiny ImageNet dataset의 (9,3) Anchor ERF heatmap




Fig B5. Tiny ImageNet dataset의 (7,7) Anchor ERF heatmap

Resize되지 않은 patch 개수가 8×8 인 CIFAR-100 dataset에 대해서도 ERF heatmap을 생성하였다. Fig B6, Fig B7, Fig B8은 (0,0)과 (3,6), (4,4)에 위치한 anchor patch에 대한 ERF heatmap이다.




Fig B6. Resize 이전 CIFAR-100 dataset의 (0,0) Anchor ERF Map




Fig B7. Resize 이전 CIFAR-100 dataset의 (3,6) Anchor ERF Map




Fig B8. Resize 이전 CIFAR-100 dataset의 (4,4) Anchor ERF Map

추가 결과에서도 5.1.1절에서 분석한 경향성이 일관적으로 유지된다는 점을 확인할 수 있다. Long range dependency를 가지는 token mixer는 그렇지 않은 token mixer에 비하여 거리에 대해 비교적 균등한 ERF 분포를 가진다. 또한 data specific weight를 가지는 ViT와 local ViT는 그렇지 않은 MLP mixer와 Convformer에 비해서 자기 자신이나 자신으로부터 1~2 떨어진 patch에 대하여 상대적으로 높은 가중치를 갖는다

C. Auxiliary ERD Results

Resize 이전 8×8 patch size의 CIFAR-100 dataset과 Tiny ImageNet에 대해서 각 token mixer에 따른 ERD 및 distance에 따른 erf의 합 그래프를 시각화하였다. 이때 전반적인 경향성은 5.1.3절과 일관적으로 유지된다는 점을 알 수 있다. 구조적인 long range dependency를 가지지 않고 data specific weight을 가지는 모델일수록 ERD가 더 작게 나타났다. 한편 pretrained ViT는 CIFAR-100에서 ERD가 6.68이었던 것에 비해 Tiny ImageNet에서는 ERD가 7.70으로 1.02 커진 것을 알 수 있다.




Fig C1. Resize 이전 CIFAR-100 dataset에서의 각 token mixer에 따른 ERD 및 Sum ERF per Distance




Fig C2. Tiny ImageNet dataset에서의 각 token mixer에 따른 ERD 및 Sum ERF per Distance

D. Layer-wise ERD

본 연구의 5.1절에서는 모델의 long range dependency를 하나의 수치로 요약하기 위해, 마지막 block의 출력이 입력 이미지로부터 받는 ERD만을 측정하였다. 그러나 이 단일 값은 모델이 최종적으로 도달한 receptive distance만을 나타낼 뿐, 그 값이 네트워크의 깊이에 따라 어떻게 형성되는지는 보여주지 못한다. 본 절에서는 ERD 분석을 모든 layer 쌍으로 확장하여, token mixer의 inductive bias가 모델 내부에서 layer를 거치며 어떻게 전개되는지를 분석한다.

구체적으로, 임의의 두 layer $a < b$ 에 대해 layer b 의 출력 patch가 layer a 의 활성값을 평균적으로 얼마나 멀리 떨어진 위치까지 참조하는지를 ERD로 측정하였다. 이때 layer index는 0이 입력 이미지, 1이 patch embedding, 2 이상이 각 metaformer block에 대응한다. 모든 쌍에 대해 계산한 ERD를 heatmap으로 나타내었으며, Fig D1과 Fig D3은 각각 CIFAR-100과 Tiny ImageNet에서 측정한 모델별 block-wise ERD heatmap에 해당한다. 한편 a 를 입력 이미지로 고정하고 출력 layer b 만을 변화시키면, receptive distance가 깊이에 따라 누적되는 양상을 하나의 곡선으로 나타낼 수 있다. Fig D2와 Fig D4는 이러한 input-to-output ERD를 layer index에 대해 시각화한 결과이다.




Fig D1. CIFAR-100에서 측정한 모델별 block-wise ERD heatmap. (위) 왼쪽부터 ViT, local ViT. (아래) 왼쪽부터 MLP mixer, Convformer, pretrained ViT이다. 그래프의 세로축은 input layer a 이며, 가로축은 anchor layer b 이다.




Fig D2. CIFAR-100에서 측정한 모델별 input-to-output ERD. Fig D1의 ERD 행렬에서 input layer를 입력 이미지($a=0$)로 고정하고 output layer index를 변화시킨 값으로, receptive distance가 네트워크의 깊이에 따라 누적되는 양상을 나타낸다. Long range dependency를 가지는 ViT, MLP mixer, pretrained ViT는 초기 layer에서부터 큰 ERD로 도약하는 반면, locality를 가지는 local ViT와 Convformer는 ERD가 깊이에 따라 점진적으로 증가한다.




Fig D3. Tiny ImageNet에서 측정한 모델별 block-wise ERD heatmap. 배열 순서와 축의 정의는 Fig D1과 동일하다.




Fig D4. Tiny ImageNet에서 측정한 모델별 input-to-output ERD. 표현 방식은 Fig D2와 동일하다. Long range dependency를 지닌 모델은 초기 layer에서 큰 ERD로 도약하고 locality를 지닌 모델은 점진적으로 증가하는 경향이 CIFAR-100에서와 동일하게 관찰되어, layer 단위 ERD 분석 결과가 데이터셋에 무관하게 유지됨을 확인할 수 있다.